SAPIENTIA
ERDÉLYI MAGYAR
TUDOMÁNYEGYETEM

Sapientia Erdélyi Magyar Tudományegyetem

Marosvásárhelyi Kar

Számítástechnika szak

3D nyomtatási folyamat monitorizálás és hibadetektálás mesterséges intelligenciával

Készítette: Borbáth Mátyás-Levente

Témavezetők: Dr. Szántó Zoltán, Dr. Fehér Áron

2026

Kivonat

A 3D nyomtatási folyamat során különböző hibák léphetnek fel, amelyek anyagveszteséget, időveszteséget és akár a berendezés károsodását is okozhatják. A dolgozat célja egy olyan valós idejű monitorizáló rendszer fejlesztése, amely képfeldolgozási módszerekkel képes felismerni a nyomtatási hibákat. A javasolt megoldás egy többkamerás megfigyelőrendszerre épül, amely a nyomtatási folyamatot folyamatosan rögzíti, majd a képkockákat egy felhőalapú környezetben futó YOLOv8 neurális hálózat dolgozza fel. A modell egy saját annotált adathalmazon került betanításra, és 9 hibaosztály felismerésére képes, és 92.6% mAP50 pontossággal és 87.3% recall értékkel rendelkezik, illetve másodpercenként 3 képkockát dolgoz fel 23 ms inferencia idővel. A rendszer része egy értesítési mechanizmus is, amely anomália észlelése esetén azonnali visszajelzést ad a felhasználónak. A kísérleti eredmények alapján a rendszer alkalmas valós idejű hibadetektálásra, és hozzájárulhat a nyomtatási folyamat hatékonyságának növeléséhez, valamint az anyagveszteség csökkentéséhez.

Kulcsszavak: 3D nyomtatás,Konvoluciós Neuronháló, YOLOv8x, Rasberry Pi, Google Cloud, vertexAI, hiba, Terraform, Docker, Firebase

Tartalomjegyzék

1. Bevezető **1**

1.1. 3D nyomtatásról 1

1.1.1. Nyersanyagok 2

1.1.2. Felmerülő hibák és limitációk 5

2. Miért született meg a projekt? **14**

2.1. A projektről TODO! 14

2.1.1. Iparági relevancia és nyersanyagmenedzsment 14

3. Mélytanulási modellek **16**

3.1. Piackutatás és a megfelelő Ai modell kiválasztása 16

3.1.1. Lehetséges eszközök 16

3.2. A projekt megvalósításához használandó AI modell- YOLOv8 18

3.2.1. Bevezetés 18

3.2.2. Főbb karakterisztikák 18

3.2.3. Modell variánsok 18

3.2.4. Telepítési útmutató és alapszíntű felhasználás 19

3.2.5. Saját dataset felhasználása tanításhoz 20

3.2.6. Annotáció formátuma 20

3.2.7. Célkítűzés 21

4. Hardver- és szoftverkörnyezet **22**

4.1. A teljes rendszer 22
4.1.1. Kamera Agent-Rasberry pi 23
4.2. Szolgáltatások a PI-n 23
4.2.1. MediaMTX 24
4.2.2. Képkockák kinyerése 24
4.2.3. Cloudflare alagút 26
4.3. Cloud Stack 26
4.3.1. Terraform keretrendszer 27
4.3.2. Terraform működése 27
4.3.3. Google Cloud Projekt - GCP 28
4.3.4. Vertex AI végpont 29
4.3.5. Service Accounts 29
4.3.6. Pub/Sub Topics 30
4.3.7. Google Cloud Függvények 31
4.3.8. Firestore Collections 32
4.3.9. Konténer képek 32
4.4. Dashboard 33
4.5. Github Action Workflows 34
4.5.1. Terraform lépések automatizálása 34
4.5.2. Docker konténer felépítésének automatizálása 35

5. Adatgyűjtés és előfeldolgozás 37
5.1. Cím 1 37

6. Modell betanítása és validálása 38
6.1. Cím 1 38

7. Tesztelés és kiértékelés 39
7.1. Összefoglalás 39

8. Rendszerintegráció és alkalmazás 40

9. Összefoglalás és jövőbeli irányok **41**

10. Mellékletek **42**

Irodalomjegyzék **42**

A. Függelék **45**

A.1. Alfejezet 45

A.1.1. Cím 45

Ábrák jegyzéke

1.1. SLA nyomtató 2
1.2. FDM nyomtató 2
1.3. Döntési szempontok 2
1.4. Filament tekercsek 5
1.5. Szálazás a nyomtatás végén 6
1.6. Eltorzult darab 7
1.7. Elcsúszott rétegek 8
1.8. Teljes alul extrúdálás 9
1.9. Lokális alul extrúdálás 9
1.10. Felül extrúdált darab 10
1.11. Nyomtatás közben eldugult fúvóka és darab 11
1.12. Figyelmetlenségből a tárgyasztalon hagyott szerszám 12
1.13. Nem tapadó első réteg 12
1.14. Hibás nyomtatást követő spagetti halmaz 13

2.1. 3D nyomtató farm[1] 15

4.1. A rendszer 23
4.2. MediaMTX stream pipeline 24
4.3. Terraform Lépések[2] 28
4.4. A `judge` konténer image életciklusa 33
4.5. A dashboard normál működési állapotban 34
4.6. A dashboard anomália detektálás esetén 34

4.7. A CI/CD pipeline lépései 36

1. fejezet

Bevezető

1.1. 3D nyomtatásról

Mi is az additív gyártás, tömören azon folyamatokat hívjuk így melyek során egy darabot rétegről rétegre készítünk el, ellentéte a szubsztraktív gyártás, melynek során a darabot, egy szolid blokkból való elvéséssel állítjuk elő. A 3D nyomtatás maga egy addítív gyártási folyamat mely CAD vagy digitális 3D modellt épít fel különböző nyersagokat felhasználva, 3D nyomtatók segítségével. A folyamat maga egy 3D modellel kezdődik, melyet úgynevezett szeletelő programok segítségével, akár több száz vagy ezer egymással párhuzamos szeletre osztunk. A szoftver ezután a szeletelt modellt G-kóddá alakítja, mely utasítások sorozatát tartalmazza a 3D nyomtató számára. A 3D nyomtató ezek alapján építi fel majd a darabot. Ma a legelterjedtebb 3D nyomtató fajták az FDM (Fused Deposition Modelling) ezek a legismertebbek és a legelterjedtebbek a világon, működése a nyersanyagként használt műanyag megolvasztásán és annak vékony szállá extrúdáláson alapul. Egy kicsit komplexebb nyomtató fajta az SLA (Stereolithography) nyomtatók, ezek nyersanyagként speciális gyantát használnak, melyeket precízen irányított lézersugarak segítségével szilárdítanak meg. Ezen nyomtatók rendkívűli részletességre képesek, és nagyon precízek, viszont a darabokkal rengeteg utómunka van. Megemlíteném még A polyjet, binder jet, és a fémnyomtatásra használt, DMLS/SLM technológiákat. A dolgozat elkészítése során FDM nyomtatókon előforduló hibákat tanulmányoztam, innentől kezdve csak velük foglalkozunk.

1.1. ábra. SLA nyomtató[1]

1.2. ábra. FDM nyomtató[2]

1.1.1. Nyersanyagok

Az FDM nyomtatók nyersanyaga a filament, de felhasználási módtól függetlenül, több anyagot különböztetünk meg. Mindegyik anyagnak megvannak a maga tulajdonságai amik alapján kiválaszthatjuk a számunkra megfelelőt.

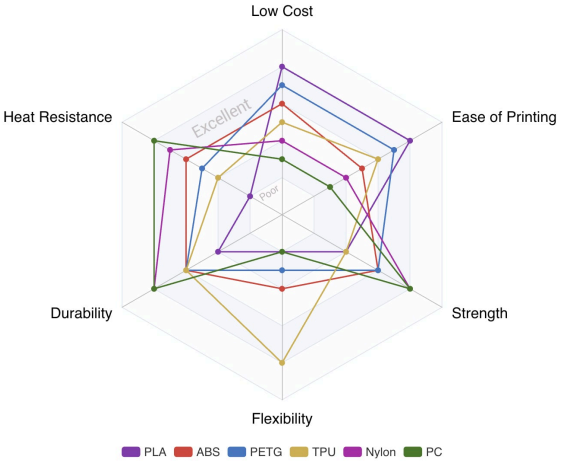

1.3. ábra. Döntési szempontok[3]

[1] *Fotó*:https://ro.pinterest.com/pin/338895940694784238/

[2] *Fotó*:https://eu.store.bambulab.com/products/a1?id=599117150694776844

PLA-Polylactic acid

A PLA legelterjedtebb filament a 3D nyomtatással foglalkozók körében. Ezen nyersanyag az egyik legkörnyezetbarátabb, hiszen megújuló, leggyakrabban kukorica keményítőből, cukornádból, tápiókából vagy más szénhidrátokban gazdag növényből állítják elő. Viszont nagyon fontos megjegyezni, hogy a közhiedelemmel ellentétben újrahasznosítása nem olyan egyszerű, csakis ipari körülmények között valósítható meg mivel magas hőt, páratartalmat és mikrobiológiai aktivítást igényel, ha ezen körülmények nem teljesülnek úgyanolyan káros mint bármilyen más műanyag a szeméthegyeken. PLA-val nyomtatni nem okoz nagy fejtörést, olvadáspontja alacsonyabb, mint más filamenteknek, mechanikai ereje a közepes kategóriába sorolható rugalmassága alacsony, színe a gyártási folyamatnak köszönhetően bármilyen lehet. Gyenge pontjai, a magas hőmérséklet és páratartalom és az UV sugárzásnak való kitettség.

ABS-Acrylonitrile butadiene styrene

Az ABS már a hobbiisták körében nem annyira elterjedt nyersanyag, mivel nyomtatása során, mérgező gázok keletkezhetnek, az ezek által okozott kár viszont megfelelő szellőztetéssel teljes mértékben elkerülhető. Az iparban nagyon szívesen nyomtatnak vele, hiszen az anyag tulajdonságai, mérsékelten jobbak mint a PLA-é, bár nyomtatása már nem olyan egyszerű, mert az anyag nagyon hajlamos a torzulása, ha ingadozik a hő a nyomtatótérben. Mechanikai keménysége magas és rugalmassága is jobb mint a pla-é. Az ABS-ből készült darabok időtállóak, nem kezdi ki őket sem a nedvesség, mintsem az uv sugárzás. Érdekesség képben kiemelném, hogy a legó kockák nagyrésze szintén ABS-ből készült.

PETG-Polyethylene Terephthalate Glycol

A PETG filament nagyszerű módon ötvözi az erőt flexibilitást, és a felhasználó barátságot, mondhatni ő az aranyközépút. Az anyag a műanyagüvegekhez is használt PET kis glycollal megfűszerezve, mely hatására kevésbé lesz törékeny és a minősége is javul. Mechanikai ereje igen magas és rugalmassága szintén közepes szintre sorolható. Az anyag rendkivűl ellenálló a nedvességgel szemben és kevésbé

[3] *Fotó*:https://all3dp.com/1/3d-printer-filament-types-3d-printing-3d-filament/

hajlamos a torzulásra. Szárítására különösen oda kell figyelni.

TPU-Thermoplastic Polyurethane

A TPU egy rendkivűl rugalmas, gumiszerű nyersanyag, mely a nyúlánkságáról keménységéről és becsapódás ellenálló képességőről híresült el. A szilárd filamentekkel szemben a TPU, hajlítható, nyújtható, összenyomható, és képess ütések elnyelésére. Mechanikai keménysége kicsit kisebb, viszont ezzel ellenben rugalmassága rendkívűl magas. Tökéletes olyan darabok nyomtatására melyek folyamatos használat alatt állnak majd, például szíjak, abroncsok és társaik. Az anyag hajlamos a szálazásra, nyúlánksága miatt, így sokkal lassabban kell nyomtatni mint a szilárd társait, a nyomatót nagyon gyakran hozzá kell majd kalibrálni.

Nylon-Polyamide

A Nylon, mint nyersanyag főként iparban használatos, nagyszerű ereje és tartóssága miatt gyakran a biztos választás. A nylon nyomtatása a fúvókák, és a zárt nyomtató terek fejlesztésével vált elérhetővé, melyekben nagyobb kontrol van a nedvesség tartalom és a hőmérséklet fölött. Mechanikai keménysége elsőosztályú, rugalmassága kiváló, tartóssága pedig messze felülmúlja társaiét.

PC- Polycarbonate

A policarbonate amellet, hogy a mai napig a világon a legkeményebb és legtartósabb filament címét tudhatja magáénak, rendkivűl ellenálló mint a hőnek mint a nedvességnek. Nyomtatása döcögős hobbiisták számára ugyanis nagyon sok hőt igényel, a zökkenőmentes nyomtatáshoz a fúvókának a 260-310°C tartományban kell lennie, és a tárgyasztalt zár térbe kell telepíteni, ezzel is gátolva a hőingadozást.

Egyébb nyersanyagok

A fent említettek mellett, persze ma már mégtöbb filament áll rendélkezésünkre, viszont ezek a dolgozat szempontjából nem annyira relevánsak, mivel a fent tárgyalt variánsok keverékei. Ilyen például, az ún selyem PLA, melynek mechanikai keménysége alacsonyabb, viszont szebb, fényesebb textúrával rendelkezik, tökéletes Olyan darabok nyomtatására, melyeknél az esztétika fontosabb mint a mechanikai felhasználás, például a dísztárgyak. Az Wood-PLA, egy olyan PLA variáns mely fa darabkákkal ötvözött, a nyomtatás után a darab fás tapintásnak örvend majd, ebből létezik fémmel ötvözött variáns is.

1.4. ábra. Filament tekercsek

1.1.2. Felmerülő hibák és limitációk

A 3D nyomtatási folyamat során rengeteg hiba felmerülhet. mely több okból is keletkezhet, a nedves anyagtól, a rossz kallibrációig, vagy akár komoly hardver hibáig is. Beszéljünk egy kicsit ezen hibákról.

Stringing- Avagy szálazás

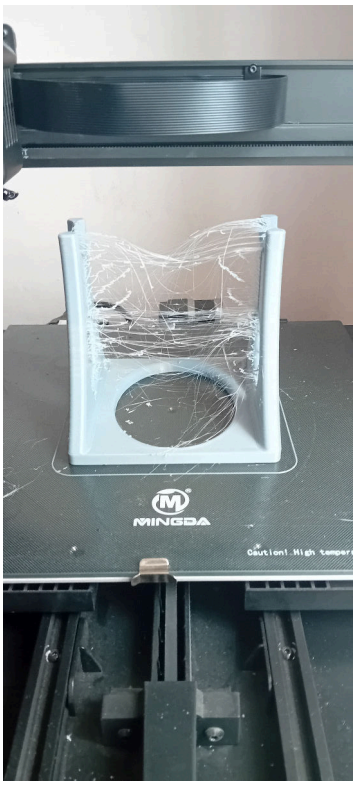

1.5. ábra. Szálazás a nyomtatás végén

Ezen hiba fő jellegzetessége apró szinte áttetsző szálak megjelenése a darab élei között, ennek oka hogy a fúvóka utazás közben olvadt műanyagot húz a levegőben amíg A pontból B pontba ér. Legfőbb oka általában nem megfelelően kiszárított filament használata a nyomtatáshoz. Ezen szálak utómunkával eltávolíthatóak, de nem garantált, hogy nyomuk teljesen eltávolítható. A hibát még okozhatja, nem megfelelő visszahúzás érték, túl forró fúvóka, és mocskos fúvóka is.

Warping- Avagy eltorzulás

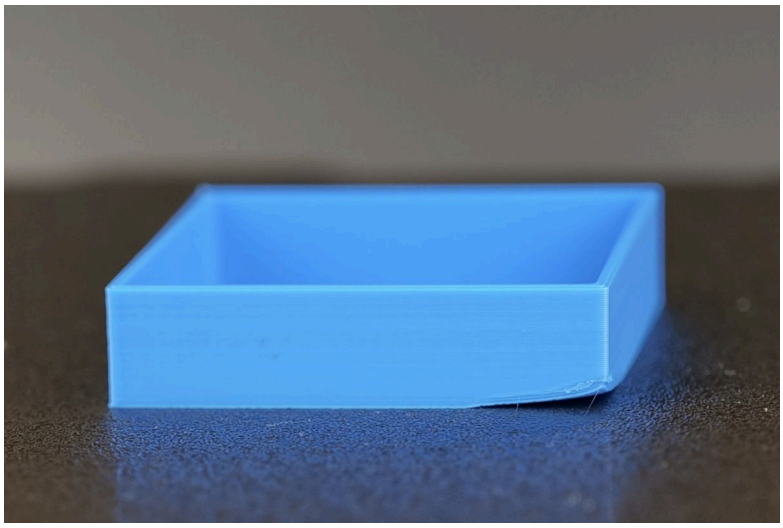

1.6. ábra. Eltorzult darab[4]

Eltorzulás legtöbbször akkor jelentkezik, amikor egy darab alján éles szögek találhatóak, például négyzet, vagy egyébb sokszög. Fontos beavatkozó viszont a tárgyasztal hője, tisztasága is a megfelelő tapadás fenttartásához. A hiba maga kiküszöbölhető egy úgynevezett skirt, avagy szoknya alkalmazásával a szeletelőben, mely búnusz tapadást biztosít a sarkakon.

[4] *Fotó*:https://wiki.bambulab.com/en/knowledge-sharing/printed-model-warping

Layer shift-Avagy réteg eltolódás

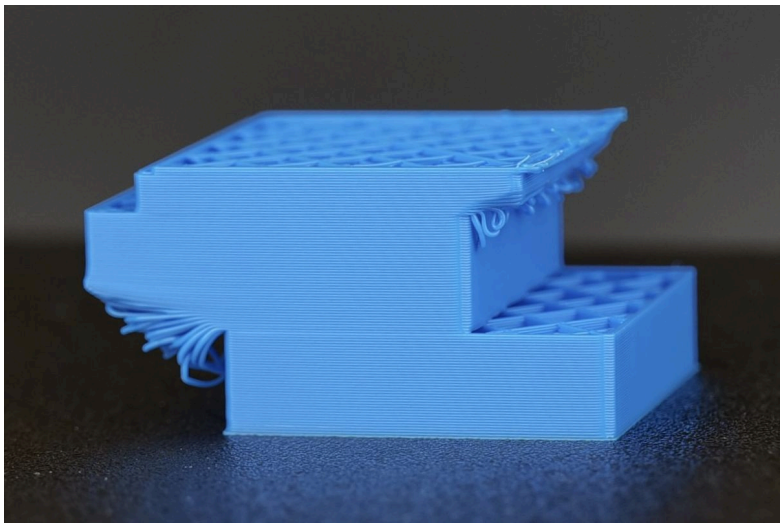

1.7. ábra. Elcsúszott rétegek[5]

A nyomtatott rétegek eltolódása végzetes hiba a darab számára. Főként akkor jelenik meg amikor eltérés van a G-kódban található koordítnáta és a fúvóka világi koordínátái között. Három fő oka van, túl nagy nyomtatási sebesség, nem megfelelő Z-offset mely miatt a fúvóka beleakadhat a darabba ezzel koordináta különbséget előídézve, vagy a nyomtatót ért fizikai trauma, esetleg laza sínek vagy merevítők.

[5] *Fotó*:https://wiki.bambulab.com/en/knowledge-sharing/layer-shifts

Under extrusion- Avagy alul extrúdálás

1.8. ábra. Teljes alul extrúdálás[6]

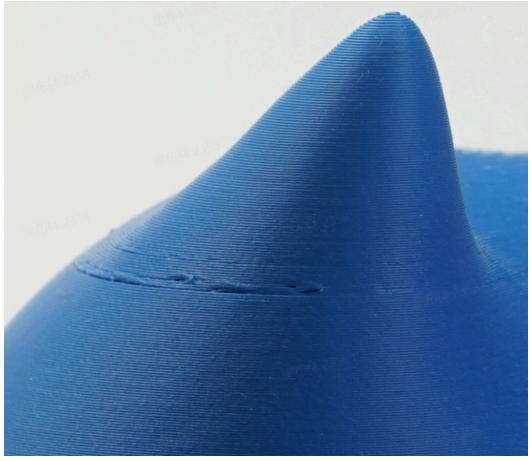

1.9. ábra. Lokális alul extrúdálás[7]

Ezen hibának két külön fajtáját különböztetjük meg, a teljes illetve a lokális alul extrúdálást. Ezen hiba okai lehetnek mind hardveres, de előokozhatja nem megfelelő szeletelés is. Főbb előidéző okok közé tartozik, hogyha, eldugul a ptfe cső, vagy idegen test kerül bele, beakadt a filament tekercs és nem jút elég a fúvókához, fogaskerék probléma, vagy részleges dugúlás a fúvókában vagy a hotendben. Amennyiben a problémát szoftveres ok váltja ki a Maximum Volumetric speed illetve Flow ratio nevű beállításokkal van a probléma. A mai modern nyomtatók már fel vannak szerelve autómatikus adagolás kallibrációval, ezzel segítve a felhasználót.

[6] *Fotó*:https://wiki.bambulab.com/en/filament-acc/filament/print-quality/under-extrusion
[7] *Fotó*:https://wiki.bambulab.com/en/filament-acc/filament/print-quality/under-extrusion

Over extrusion- Avagy felül extrúdálás

1.10. ábra. Felül extrúdált darab[8]

Ugyanazon probléma mint az alul extrúdálás, egy annyi csavarral, hogy itt nem túl kevés anyag jut a fúvókához hanem pont, hogy túl sok.

[8] *Fotó*:https://www.3dsourced.com/guides/3d-print-over-extrusion/

Nozzle Clog- Avagy fúvóka dugulás

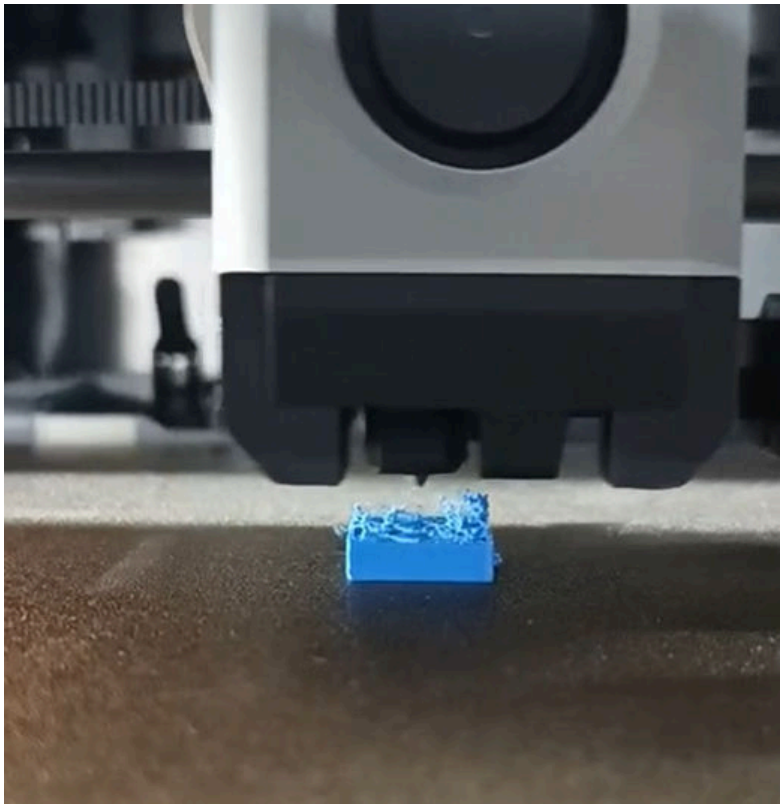

1.11. ábra. Nyomtatás közben eldugult fúvóka és darab[9]

Egy sajnos igen gyakori probléma mely akár a nyomtatónk "életébe" is kerülhet. Legfőbb oka, hogy a filament amikor a ptfe csövön keresztül a forró kamrába, majd pedig a fúvókába jut nem teljesen tiszta, kis por vagy egyébb szennyező anyagok is bekerülnek, melyek a fúvóka dugulását okozhatják. Amennyiben nem vesszük észre hamar az olvadt műanyag felgyülhet a fúvókában és belülről szétfeszíti azt, ezzel jelentős anyagi kárt okozva.

Foreign object on the printbed- Avagy idegen tárgy a tárgyasztaklon

Ezen hiba se nem hardveres se nem szoftveres hanem szimplán a kezelő figyelmetlensége miatt következik be, akik a tapasztalatomból legtöbbször olyan izgatott a szeletelést követően, hogy elfelejti ellenőrizni, hogy leürítette-e a tárgyasztalt, vagy csak karbantartás után nem pakolt el maga után.

[9] *Fotó*:https://wiki.bambulab.com/en/filament-acc/filament/print-quality/clog

Az idegen tárgyak a fúvókában és a fejben súlyos anyagi kárt okozhatnak viszont, hiszen a legtöbb nyomtató nem képes detektálni, ha a tárgyasztal üres vagy sem.

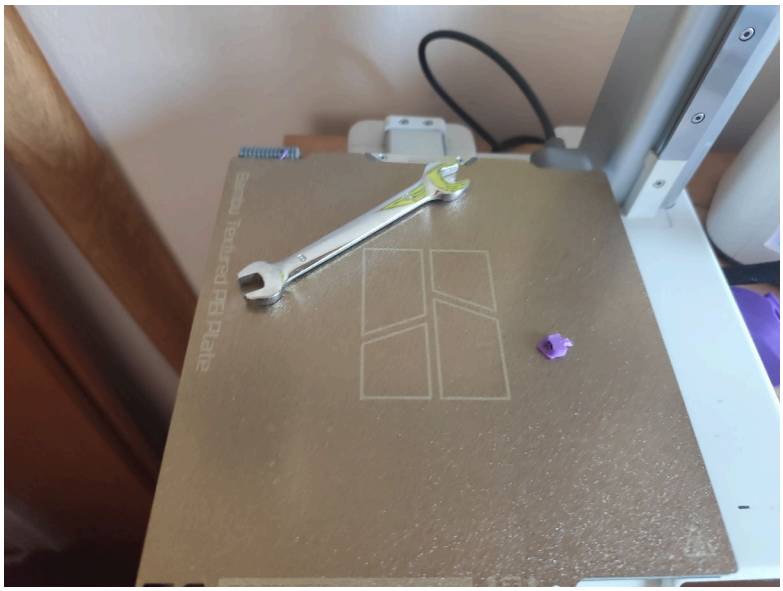

1.12. ábra. Figyelmetlenségből a tárgyasztalon hagyott szerszám

First layer not sticking- Avagy az első réteg nem tapad

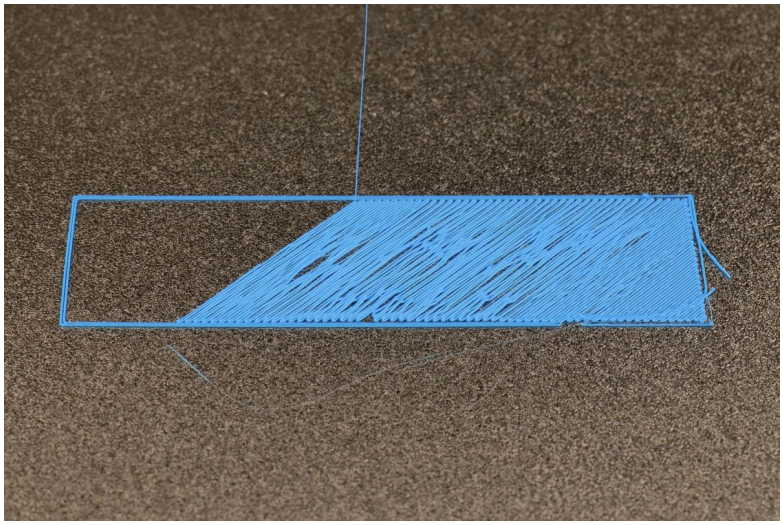

1.13. ábra. Nem tapadó első réteg[10]

[10] *Fotó*:https://wiki.bambulab.com/en/knowledge-sharing/first-layer-not-sticking

A 3D nyomtatási folyamat során a legfontosabb mozzanat az első réteg, ha ez nem tapad oda akkor az egész darab kuka, fontos figyelemmel kísérni, amennyiben észrevétlen marad, az Spagettihez, és rengeteg anyag veszteséggel jár. Főbb okai, ha a tárgyasztal nem megfelelő tisztaságú, rossz fúvóka tárgyasztal távolság (Z-offset), vagy rossz asztal szintezés. Könnnyen elkerülhető a megfelelő beállításokkal és a tárgyasztal karban-és tisztán tartásával.

Spagetti- Avagy az anyag a levegőbe adagolódik

Rengeteg oka lehet, de a legfőbb előokozója, ha az első réteg nyomtatási folyamata sikertelennek bizonyult, a fúvókát ez nem érdekli, ő követi a G-kód által megadott utasításokat és addig nyomja a levegőbe az anyagot, ameddig a végére nem ér, vagy a kezelő azt meg nem állítja. Fontos kiemelni, hogy a tapadás elvesztése a nyomtatási folyamat bármely pillanatában bekövetkezhet, amennyiben nem megfelelő support beállításokat alkamaztunk a szeletelőben, vagy éppen a supportok engedik el a tárgyasztalt, ezzel védtelenül hagyva a darabot.

1.14. ábra. Hibás nyomtatást követő spagetti halmaz

2. fejezet

Miért született meg a projekt?

2.1. A projektről TODO!

A 3D nyomatás folyamat során rengeteg hiba bekövetkezhet, melyek kihatnak a nyomtatott darab minőségére, anyagi kárt okoznak, súlyosabb esetben a nyomató életébe is kerülhetnek. A folyamat valós idejű monitorizálásával, és jól tanított konvoluciós neurális hálózatok segítségével ezen hibák egy igen nagy része felismerhető. A hibákat két kategóriába sorolnám: Nyomatás közben korrigálható, és azonnal félbeszakítandó hibák. A projekt célja egy olyan rendszer létrehozása, mely valós időben monitorizálja a 3D nyomatási folyamatot, minden lehetséges szögből, Felismeri az adott hibát, és ennek megfelelően értesíti a felhasználót a teendőkről. Ezzel jelentős, költséget, időt és nyersanyagot megspórolva a felhasználónak.

2.1.1. Iparági relevancia és nyersanyagmenedzsment

A 3D nyomatás a jelenben már egy igen komoly iparággá nőtte, ki magát, tekintettel lévén arra, hogy Rengeteg új geometria megvalósítására nyitott kapukat, az additív gyártásban, és rendkívűl egyszerűvé tette a prototípus gyártást, ezzel gyorsítva a tömeggyártáshoz való eljutást. De miért is fontos a valós idejű monitorizálás? Egy hobbiista, akinek egy nyomtató ül az asztalánál megengedheti magának, hogy időközönként ránézzen és közbelépjen amenyiben ez indokolt, viszont az iparban, ahol egy nyomtatófarmon belül akár száz nyomtató is lehet ezt már nem engedhetjük meg magunknak,

automatizálni kell.

2.1. ábra. 3D nyomtató farm[1]

Egy ilyen farm esetén, már egy szeletelési hiba is, ha észrevétlen marad anyagi kárral, nyersanyagveszteséggel vagy a berendezések sérülésével járhat. A 3D nyomtatási folyamatok egyik nagy problámája az, hogy igen csak időigényesek, és a nagyszámok törvénye alapján a hibák bekövetkezésének esélye is növekszik. A projekt keretein egy olyan skálázható rendszert szeretnénk megvalósítani, mely képes minden nyomtatón, több szögből, figyelni a darabokat, és hiba kategóriának megfelelően jelezni amenyiben beavatkozásra van szükség. Az alapötlet: Egy olyan konvoluciós neuron háló betanítása mely képes felismerni az alap hibákat, es ennek a beillesztése egy olyan keretrendszerbe, mely a tárgyasztalokat figyeli, különböző szögekből.

[1] *3D nyomtató farm*: https://www.voxelmatters.com/the-rise-of-3d-printer-farms/

3. fejezet

Mélytanulási modellek

3.1. Piackutatás és a megfelelő Ai modell kiválasztása

3.1.1. Lehetséges eszközök

Képfelismerésre, több ai keretrendszer felhasználható, már nem kell abban gondolkozni, hogyha megszeretnénk valósítani valamit akkor fel kell építenünk egy egész neuron hálót a semmiből, viszont fontos, hogy olyat válasszunk mely számunkra a legmefelelőbb a cél megvalósításhoz. Amikor a projekt körvonalazódott a fejemben, az ultralytics yolov5 gondolata jelent meg mivel már dolgoztam vele, az egyetemi Mesterséges Intelligencia tantárgy során tudom, mire képes. De azért további utána olvasás során rá kellett jönnöm, hogy nem feltétlen ez a legjárhatóbb út, vannak jobb megoldások. Egy nagyon fontos szempont volt a választásban, hogy a tanított modell könnyen integrálható legyen egy olyan pipeline-ba mely nagyban kapaszkodik a Jupyter Notebook, majd később a Google Cloud által kínált erőforrásokba, ezzel megkerülve a tanítás és futtatás során felmerülő hardverbéli megszorításokat.

Faster R-CNN

A Faster R-CNN, azaz régió alapú konvolúciós neuron háló, úgynevezett kétfázisú obiektum észlelő neurális háló. Megjelenése 2015-re vezethető vissza a Microsoft Research kutatói rukkoltak elő vele. Működési elve röviden három lépésre bontható. Először végbemegy a jellemző kivonás, mely során

egy előre betanított konvoluciós háló vizuális jellemzőtérképet készít a bebementi képből. Ezt követi a Region Proposal network felépítése, ezen folyamat során generálódnak ki a lehetségers jelöltek, jelentősen gyorsabb mint a manuális régió kereső algoritmusok.A harmadik egyben utolsó lépcsőfok a Rol pooling és az osztályozás, ebben a jellemző térképből kivágódnak a javasolt régiók, majd egységes méretre skálázás történik, ez a Rol pooling. Végezetül egy másodlagos hálózat minden régiót egyenként kiértékel, és megmutatja melyik régió melyik obiektumhoz társul majd egyben pontosítja a határoló doboz koordinátáit. A Faster R-CNN modell előnyei, a magas pontosság, melyet a kétfázisu feldolgozásnak köszönhet. Az előre betanított konvulicós háló nagyon rugalmas, és könnyen összehangolható más konvoluciós neuron hálókkal, ezáltal a háló teljesítménye skálázható. Hátrányai miatt számunkra rossz alternatívává válik, hiszen lassú interferenciája miatt, nem képes valósidejű alkalmazások megvalósítására. A modell mérete is szintén elég nagy mely erős hardverigényt jelent. Integrálása a Jupyter Notebook-ba is sokkal elvontabb mint például a Yolo család tagjaié.

Yolov5

A Yolov5 avagy You Only Look Once 5ös verziója, egy egyfázisű objektumdetekciós neurális hálózat. 2020-ban adta ki az Ultralytics nevű cég. Eléggé széleskörben elterjedt az iparban mivel, nagyon könnyen használható, és tanítható, és nagyon könnyen integrálható. A Yolo Architektúra is h árom részből épül fel. Az első a Gerinc mely a képből kinyeri a vizuális jellemzőket, majd a Yolov5 a Cross Stage partial Darknet elvégzi a számításokat. Ez a réteg felel az összes vizuális mintázat felismeréséért, melyből később majd a háló tanulni fog. Az architecktúra második része a nyak, mely először összevonja a különböző méretű jellemzőket, biztosítva hogy a modell több méretű obiektum felismerésére is képes legyen. A harmadik rész a fej, ezen rétegben történik a felismerés, ez egy horgony alapű réteg, a háló előredefiniált méretű dobozat próbál végig. Maga a kimenet három méretben jön létre. Előnyei közül kiemelendő, hogy kis interferencia ideje van, ezáltal tökéletes a valós idejű felismerésre modellmérettől függően. Nagyon könnyen tanítható és integrálható, szinte out of the box használható. Jól dokumentált és rengeteg segédanyag található az interneten, és a Hyperparaméterek augmentációk és a veszteség függvények is előre bevannak már állítva. A yolov5 egy jó kandidátus a projektünk szempontjából, de újabb variánsa a Yolov8 még az ő hiányosságain is felülkerekedik, mivel a teljes Architektúrát újragondolták,ő jobb pontosságot és sebességet kínál, és a detekció sem

horgony alapű már.

3.2. A projekt megvalósításához használandó AI modell- YOLOv8

3.2.1. Bevezetés

A YOLOv8 (*You Only Look Once*,8-as verziója)-at az ultralytics cég adta ki 2023-ban. Egy olyan modell, mely rendkívűl hasznos a valósidejű obiektumdetektációban, emiatt is esett rá a választás, minden karakterisztikája megfelelő, ha 3D nyomtatási folyamatot szeretnék felügyelni, és az esetlegesen felmerülő hibákat észrevenni esetleg közbelépni. De mégis mi mi teszi a YOLOv8-at az általunk felhasznált csodafegyverré?

3.2.2. Főbb karakterisztikák

A Yolov8 keretrendszerhez az Ultralytics teljes mértékben újragondolta a rendszer architektúráját, A Pytorch helyett most más saját fejlesztésű rendszert használ, ennek segítségével a modell gyorsabb és stabilabb lett, viszont a Yolov5 felé visszafele inkompatibilitást jelent. Ezen keretrendszer támogat az obiektum detekción kivűl, szegmentálást, pozició becslést, obiektum osztályozást és követést is egyaránt. A tanítás és detekció most már nem igényel segéd scripteket sem, minden API hívásokkal valósul meg a CLI-n keresztül. Ugyanitt lehetőségünk van a modellünk exportálására olyan formátumokba, mint az ONNX, CoreML, és TensorRT.

3.2.3. Modell variánsok

Felhasználási célok és hardverigény szerint a YOLOv8 több méretben elérhető, hogy több felhasználást legyen képes kiszolgálni.

3.1. táblázat. YOLOv8 modell variánsok

Modell	**Méret**	**Leírás**
`yolov8n`	Nano	A legkisebb variáns, rendkívül gyors és minimális hardverigényű.
`yolov8s`	Small	Kis méretű modell, gyors interferenciával, alacsony erőforrásigénnyel.
`yolov8m`	Medium	Kiegyensúlyozott kompromisszum sebesség és pontosság között.
`yolov8l`	Large	Nagy pontosságú modell, erősebb GPU-t igényel.
`yolov8x`	Extra Large	A legnagyobb pontosságot nyújtó variáns, egyúttal a legtöbb erőforrást igénylő.

3.2.4. Telepítési útmutató és alapszíntű felhasználás

Telepítés:

```
pip install ultralytics
```

Alap példa képfeldolgozásra:

```
from ultralytics import YOLO
model = YOLO("yolov8n.pt")
results = model("stringing.jpg")
results.show()
```

3.2.5. Saját dataset felhasználása tanításhoz

Mint már említettem a modell tanítható saját adathalmaz segítségével is, amennyiben az megfelelően fel lett címkézve és az exportált annotációk formátuma is Yolo kompatibilis. Ahhoz, hogy ez lehetséges legyen egy `data.yaml` fájlra lesz szükségünk, mely minden fontos információt tartalmaz. Tanítási és Validációs adathalmazok helye, osztályok számossága és elnevezése.

A `data.yaml` konfigurációs fájl tartalmazza az adathalmaz elérési útjait és az osztálycímkéket:

```
train: images/train
val: images/val
nc: 8
names: ['stringing', 'warping', 'layer_shift', 'under_extrusion',
        'over_extrusion', 'nozzle_clog', 'foreign_object_on_print_area',
        'not_sticking', 'spagetti']
```

Tanítási folyamat elindítása parancssoron keresztül:

```
yolo task=detect mode=train model=yolov8n.pt data=data.yaml epochs=50 imgsz=640
```

3.2.6. Annotáció formátuma

YOLO-formátumban minden kép mellé tartozik egy azonos nevű .txt file melynek tartalma a következőképpen néz ki, minden sor egy obiektum, egy .txt file pedig több obiektumot is tartalmazhat:

```
<class_id> <x_center> <y_center> <width> <height>
```

Az obiektumokat leíró értéket lebegőpontos ábrázolás módban vannak, kifejezve, egyenként a képpel arányosan 0-1 közötti értékekre normalizálva. Az annotáláshoz CVAT szoftvert használtam.

3.2. táblázat. YOLOv8 előnyei és hátrányai a projekt szempontjából

Előnyök	**Hátrányok**
Valós idejű objektumdetektálás	Nagy modellek (pl. YOLOv8x) jelentős GPU erőforrást igényelnek
Egyszerű és megismételhető tanítási folyamat	Kis adathalmazon hajlamos túltanulásra
Kis modellek is magas pontosságot érnek el	Zsúfolt vagy részben takart objektumok detektálása nehézkes
Docker konténerizációs támogatás	Valós idejű feldolgozás hálózati késleltetéstől függhet
Aktív közösség és folyamatos fejlesztés	Egyedi osztályokhoz saját adathalmaz gyűjtése szükséges

3.2.7. Célkítűzés

Mivel a keretrendszer és az erőforrások is adottak voltak, így a választás a yolov8x alapmodelre esett, a célkítűzés tiszta, egy olyan modelt betanítani mely képes élő kamera bemeneten felismerni a 9 hiba bármelyikét, és annak egy olyan keretrendszerbe illesztése, mely ezt elegáns módon lehetővé teszi.

4. fejezet

Hardver- és szoftverkörnyezet

4.1. A teljes rendszer

A rendszer egy edge–cloud hibrid architektúrára épül, amelynek két fő pillére van: egy helyszínen elhelyezett Raspberry Pi edge eszköz, valamint a Google Cloud Platform felhőinfrastruktúrája. A Pi feladata a kamerás képrögzítés és az adatok előfeldolgozása, míg a felhő végzi a gépi tanulás alapú hibadetekciót, az adattárolást és a felhasználói értesítéseket. Az adatfolyam iránya: Raspberry Pi → Pub/Sub (`frames-in`) → Dispatcher Cloud Function → Vertex AI végpont (YOLO inferencia) → Pub/Sub (`detections-out`) → Alert-Manager Cloud Function → Firestore + e-mail értesítés → Dashboard.

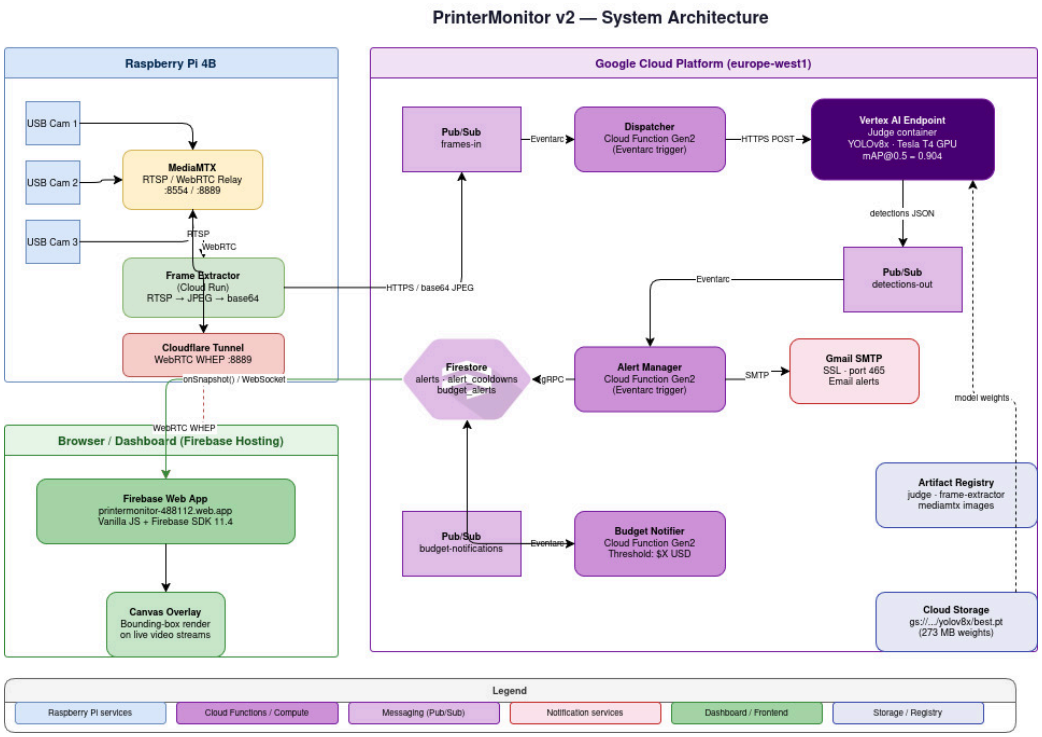

4.1. ábra. A rendszer

4.1.1. Kamera Agent-Rasberry pi

A kamera képek előállításért felelő kamera Agent szerepét egy rasberry pi 4b 8gb tölti be,[1] 3 darab rácsatolt webkamerával kiegészítve. A rasberry pi mint edge eszköz egy elég verszatilis fegyver a kezünkben. Keveset is fogyaszt, megfelelő számú usb porttal is rendelkezik, és az erőforrások is megfelelőek számunkra. A rasberry Os, pedig tökéletes a szükséges docker konténerek és python scriptek futtatására.

4.2. Szolgáltatások a PI-n

A pi-n három szolgáltatás fut, melyek az indítás után azonnal elindulnak systemd szolgáltatásként. Ezek nélkül a rendszer nem valósulhatna meg.

4.2.1. MediaMTX

A MediaMTX (korábban rtsp-simple-server) egy könnyűsúlyú, nyílt forráskódú médiaközvetítő szerver, mely Go programozási nyelven íródott.[2] Szerepe a rendszerben, hogy a webkamerák által előállított nyers videófolyamokat RTSP protokoll szerint tegye elérhetővé a hálózaton. A pi-n systemd szolgáltatásként fut, így az eszköz indításakor automatikusan elindul, emberi beavatkozás nélkül. Konfigurációs fájlja definiálja a három kamerastream elérési útját, a kódolási paramétereket, valamint az újracsatlakozási logikát. A H264-es kódolású RTSP végpontokat a Cloudflare alagúton keresztül éri el a dashboard, ahol WebRTC formátumban kerülnek megjelenítésre.

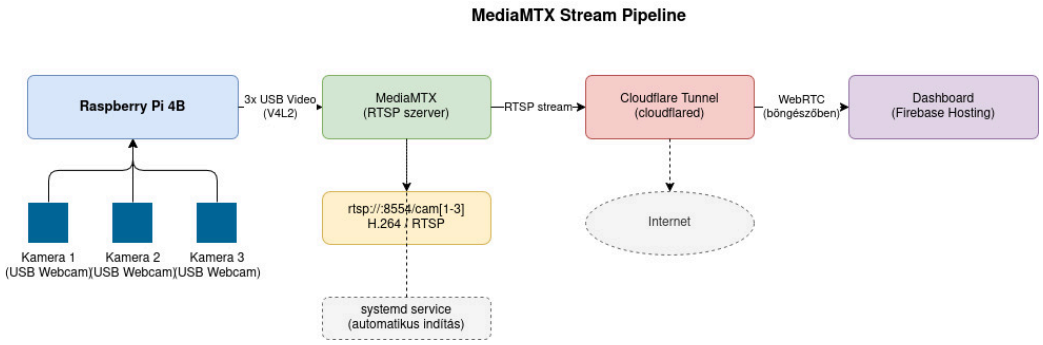

4.2. ábra. MediaMTX stream pipeline

4.2.2. Képkockák kinyerése

A képkockák kinyerésért a `frame-extractor` szolgáltatás felelős, melynek belépési pontja a `main.py` Python script. Feladata, hogy a három RTSP streamből folyamatosan képkockákat olvasson ki, azokat feldolgozza, majd JSON üzenetként publikálja a `frames-in` Pub/Sub csatornára, ahonnan a `dispatcher` Cloud Függvény továbbítja őket a Vertex AI végpontra. A szolgáltatás a pi-n systemd szolgáltatásként fut, és az `sa-frame-extractor` service account kulcsával hitelesíti magát a Google Cloud felé.

Szálkezelés és capture loop

A script induláskor beolvassa a kamerák RTSP URL-jeit és azonosítóit a környezeti változókból, majd minden egyes kamerához egy dedikált szálat (`threading.Thread`) indít. Minden szál egy önálló `capture_loop` függvényt futtat, amely az OpenCV[3] `VideoCapture` osztályán keresztül csatlako-

zik az adott RTSP streamhez. Ha a kapcsolat megszakad — például a kamera újraindul vagy a hálózat elvész —, a loop automatikusan újracsatlakozást kísérel meg 5 másodpercenként, így a rendszer emberi beavatkozás nélkül helyreáll.

Képfeldolgozás és publikálás

Sikeres kapcsolat esetén a loop `CAPTURE_FPS` (alapértelmezetten 2 fps) sebességgel olvas képkockákat. Minden egyes képkockán a következő feldolgozási lépések hajtódnak végre:

1. Az OpenCV a kamera natív felbontásáról átméretezi a képet a konfigurált `FRAME_WIDTH` × `FRAME_HEIGHT` méretre (alapértelmezetten 640×480 pixel).
2. A képkocka JPEG formátumba kerül kódolásra a beállított `JPEG_QUALITY` értékkel (alapértelmezetten 70), csökkentve az átviteli méretet.
3. A JPEG bájttömb Base64 kódolással ASCII szöveggé alakul, hogy JSON üzenetbe ágyazható legyen.
4. A script egy JSON objektumot állít össze, amely tartalmazza a `camera_id` azonosítót, a `seq` szekvenciaszámot, az `ts` UTC-időbélyeget, valamint a `data_b64` mezőt a Base64-kódolt képpel.
5. A kész JSON payload publikálásra kerül a Pub/Sub `frames-in` topicra.

Health check szerver

Mivel a szolgáltatás Cloud Run-kompatibilis konténerként is üzemeltethető, a script egy egyszerű HTTP szervert indít a `PORT` környezeti változóban megadott porton (alapértelmezetten 8080). Ez a szerver minden `GET` kérésre `200 OK` választ ad, lehetővé téve a platform számára, hogy ellenőrizze a konténer élettartamát.

Konfiguráció

A script teljes mértékben környezeti változókon keresztül konfigurálható, nem tartalmaz beégetett értékeket. A legfontosabb paramétereket az alábbi táblázat foglalja össze:

Változó	Alapértelmezett	Leírás
`GCP_PROJECT`	— (kötelező)	Google Cloud projekt azonosítója
`FRAMES_TOPIC`	— (kötelező)	Pub/Sub topic neve
`RTSP_URLS`	— (kötelező)	Vesszővel elválasztott RTSP URL-ek
`CAMERA_IDS`	cam1,cam2,cam3	Kamera azonosítók
`CAPTURE_FPS`	2	Másodpercenkénti képkockák száma
`JPEG_QUALITY`	70	JPEG tömörítési minőség (0–100)
`FRAME_WIDTH`	640	Képkocka szélessége pixelben
`FRAME_HEIGHT`	480	Képkocka magassága pixelben
`PORT`	8080	Health check HTTP szerver portja

4.1. táblázat. A `frame-extractor` konfigurációs paraméterei

4.2.3. Cloudflare alagút

A Cloudflare Tunnel egy fordított proxy megoldás, amely lehetővé teszi, hogy a Pi-n futó szolgáltatások nyilvánosan elérhetők legyenek anélkül, hogy a routeren portot kellene nyitni, vagy statikus IP-cím szükséges lenne.[4] A `cloudflared` démon a Pi-ről kifelé irányuló titkosított kapcsolatot épít fel a Cloudflare hálózata felé, így a tűzfal és a NAT nem akadályozza az elérést. Ez különösen fontos a RTSP videóstreamek dashboardra való eljuttatásakor.

A Pi-n ez is systemd szolgáltatásként fut, az induláskor automatikusan csatlakozik. Jelenleg ideiglenes (*quick tunnel*) alagutakat használunk, amelyek ingyenesek, azonban minden újraindításkor új, véletlenszerű URL-t kapnak, és időnként megszakadhatnak. Egy esetleges éles üzembe helyezés esetén célszerű lenne állandó (*named tunnel*) alagútra váltani, amely fix URL-t biztosít és robusztusabb kapcsolatot nyújt.

4.3. Cloud Stack

A rendszer lelke teljes valójában a google cloudban található, mely igen széleskörű eszköztárat biztosított számomra a projekt megvalósításához. Az infrastruktúra felépítéséhez Terraform keretrendszert

használtunk.

4.3.1. Terraform keretrendszer

A terraform egy deklaratív nyelvezetű keretrendszer, mely használatával bármilyen infrastruktúrai elem és erőforrás definiálható emberek számára is értelmezhető nyelven.[5] Ezen megvalósítások, verziózhatóak, disztributálhatóak és bármikor újrafelhasználhatóak. Segítségével az alkalmazás minden életszakasza könnyűszerrel menedzselhető, ugyanitt maga az egész folyamat rendkivül könnyen automatizálható.

4.3.2. Terraform működése

A terraform a különböző cloud platformok erőforrásait a saját Api-jain keresztül menedzseli, a közösségnek hála ma már szinte bármelyik szolgáltató rendszerét használhatjuk a terraformon keresztül. Például AWS, Google Cloud, Kubernetes, Git stb. A terraform működése 3 fázisban történik:

Írás-Write

Definiáljuk az erőforrásokat, melyek akár több szolgáltatótól is származhatnak, egy .tf kiterjesztésű fileba.

Tervezés-Plan

A terraform plan parancs kiadása után, létrejön a terv, mely leírja az infrastruktúrát, mi jön létre, mi változik vagy éppen mi szűnik majd meg. Az általunk megadott Konfigurációs fileoknak megfelelően.

Alkalmazás-Apply

Engedélyezés esetén a terraform elvégzi a szükséges műveleteket, tiszteletben tartva az erőforrások közötti függőségi sorrendet. Létrehozza, módosítja vagy törli az érintett erőforrásokat, majd frissíti az állapotfájlt (`terraform.tfstate`), amely a valós infrastruktúra leképezéseként szolgál a jövőbeli futtatásokhoz.

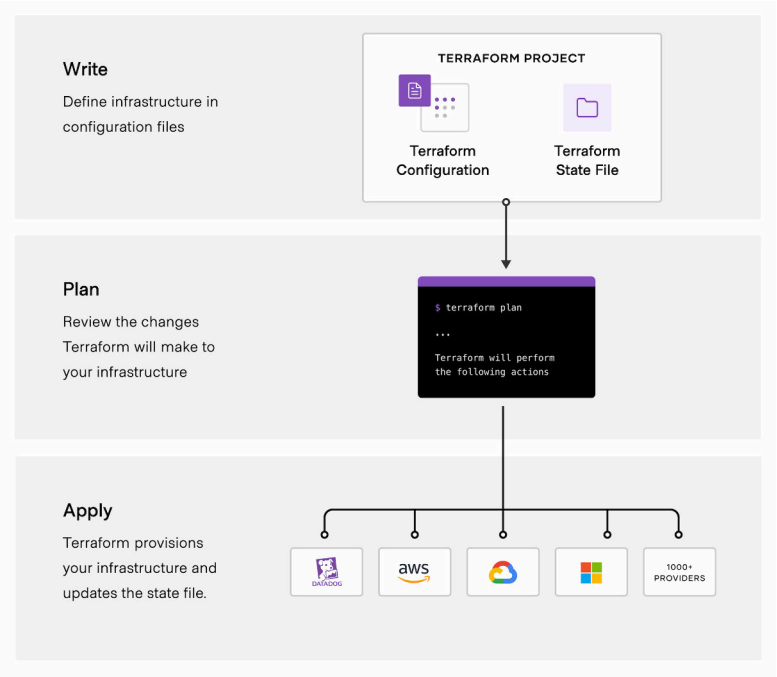

4.3. ábra. Terraform Lépések[1]

4.3.3. Google Cloud Projekt - GCP

A rendszer cloud-oldali erőforrásai egyetlen Google Cloud Projektbe szervezett infrastruktúrán futnak, amelynek egyedi azonosítója `printermonitor-488112`. Az összes felhőszolgáltatás — az Artifact Registry-től a Vertex AI végpontig, a Cloud Function-öktől a Firestore adatbázisig — ezen a projekten belül van definiálva és menedzselve. A Google Cloud Platform (GCP) választásának fő indoka az volt, hogy egységes ökoszisztémát biztosít a gépi tanulási pipeline-hoz: a Vertex AI natívan integrálódik a Pub/Sub üzenetsorral, a Cloud Functions-szel és az Artifact Registry-vel, minimalizálva az integrációs komplexitást.[6] Az erőforrások számlázása és a költségvetési riasztások szintén ezen a projekten belül vannak konfigurálva, lehetővé téve a kiadások szoros nyomon követését.

[1] *Terraform*: https://developer.hashicorp.com/terraform/intro/

4.3.4. Vertex AI végpont

A Vertex AI végpont a detekciós pipeline magja: egy egyedi `judge` Docker konténert futtat, amelyen belül a betanított YOLOv8[7] modell végzi a képkockák valós idejű elemzését. A konténer induláskor betölti a modellt a `MODEL_PATH` által megjelölt `best.pt` fájlból, majd egy HTTP szerveren (`/predict` végpont) vár a bejövő kérésekre.

A szerver kétféle üzenetformátumot kezel: a Vertex AI natív `{"instances": [...]}` formátumát, amelyet a Dispatcher Cloud Function küld, valamint a Pub/Sub push formátumát. Minden beérkező képkockát Base64-ból visszaalakít, OpenCV-vel dekódol, majd a YOLO modellel elvégzi az objektumdetekciót. Az eredmény tartalmazza az észlelt hibaosztályokat (`label`), azok konfidenciaértékeit, valamint a határoló téglalapok koordinátáit mind pixel-, mind normalizált formában. A detekciós eredmény ezt követően publikálásra kerül a `detections-out` Pub/Sub csatornára.

A végpont csak aktív használat közben generál költséget: tétlen (kitelepített, de nem hívott) állapotban nem számlázódik, míg folyamatos terhelés esetén napi körülbelül 37$-os költséggel kell számolni.

4.3.5. Service Accounts

A szervíz felhasználók, olyan egyedi emailcímmel rendelkező entitások, melyek segítségével, különböző applikációk, virtuális gépek, vagy egyéb megvalósítások kommunikálhatnak a Google Api-val, emberi felhasználók helyett, ezzel biztonságos összeköttetést biztosítva a különböző erőforrások között.

sa-frame-extractor

A pi-n fut szerepe, hogy a kinyert képkockák publikálva legyenek a pub/sub csatornára. Jogosultságai, hogy publikál a frames-in csatornára, és aiplatform felhasználó

sa-dispatcher

Az ő szerepete hogy leossza a streameket, és meghívja a VertexAi endpointot. Jogosultságai, hogy aiplatform felhasználó, pub/sub feliratkozó a detections-out csatornán, és aktiválhatja az Alert-managert

szügség esetén

sa-alert-manager

A figyelmeztetés kezelésért felelő, egyaránt az anomáliák észlelésekor, és a költségvetés meghaladásakor. Jogosultságai: `datastore.user`, `firebase.admin`, `eventarc.eventReceiver`, `pubsub.subscriber`, `run.invoker`.

sa-cicd

Mivel az, hogy a terraform infrát mi kézzel szerkesszük nem egy jó praktika, így ehhez egy automatizált github akciót használunk, ezzel szervíz pont ennek kezeléséért felelős. Jogosultságai: `artifactregistry.writer`, `pubsub.admin`, `editor`, `iam.serviceAccountUser`

Vertex AI agent

A Vertex AI endpoint a `judge` (bíró) Docker konténer futtatásáért felelős. Jogosultságai: `pubsub.publisher` a `detections-out` csatornán.

Pub/Sub agent

A Pub/Sub csatornák menedzselésére szolgál. Jogosultságai: `iam.serviceAccountTokenCreator`.

4.3.6. Pub/Sub Topics

A Google Cloud Pub/Sub egy aszinkron üzenetközvetítő szolgáltatás, amely lehetővé teszi az alkalmazáskomponensek közötti laza csatolású kommunikációt.[8] A rendszer három darab pub/sub csatornát használ, melyek a következők: `frames-in`, mely a még nyers képkockákat továbbítja a pi-től a Vertex AI végpont felé. A `detections-out`, mely a Vertex AI végpont által észlelt anomáliák eredményét továbbítja a dashboard felé, és a `budget-notifications`, mely figyelmeztet minket amennyiben átléptük a kiszabott költségvetést.

4.3.7. Google Cloud Függvények

A rendszer három Cloud Function (Gen2) példányt alkalmaz, amelyek Pub/Sub eseményekre triggerelődnek és kiszolgáltatás nélkül, skálázhatóan futnak.[6] Mindhárom függvény az `sa-alert-manager` illetve `sa-dispatcher` service account jogosultságaival rendelkezik.

Dispatcher

A Dispatcher hidat képez az edge eszköz és a Vertex AI végpont között. A `frames-in` Pub/Sub csatornáról kap üzenetet, amelynek tartalma egy Base64-kódolt JPEG képkocka, a kamera azonosítója, egy szekvenciaszám és egy UTC időbélyeg. A függvény ezt az adatot a Vertex AI REST API-jára továbbítja (`/predict` végpont), OAuth2 Bearer tokennel hitelesítve. Ha a Vertex AI kérés hálózati hiba miatt meghiúsul, a függvény újra dobja a kivételt, így a Pub/Sub automatikusan újrapróbálkozik. A három Cloud Függvény közül ez a leginkább memóriaigényes, mivel képkockák bináris adatát szállítja HTTP-n keresztül.

Alert-Manager

A detekciós pipeline záró állomása. A `detections-out` csatornáról érkező üzenetekből kiszűri azokat a detektált hibákat, amelyek konfidenciaértéke eléri a beállított küszöböt (alapértelmezetten 35%). Az átmenő detektálásokat a Firestore `alerts` kollekcióba írja, rögzítve a kamera azonosítóját, az észlelt hibákat, az időbélyeget és a szekvenciaszámot.

E-mail értesítést kizárólag magas súlyosságú hibaosztályok esetén küld: `spagetti`, `not_sticking`, `layer_shift` és `warping`. Az ismétlődő riasztások elkerülése érdekében kameránként 60 másodperces visszatartási időt (*cooldown*) alkalmaz, amelyet a Firestore `alert_cooldowns` kollekcióban tárol. Az e-mail HTML formátumú, tartalmazza az észlelt hibák táblázatát és egy közvetlen linket a dashboardra.

Budget Notifier

E függvény célja, hogy megakadályozza a felhőköltségek elszabadulását. A `budget-notifications` Pub/Sub csatornán hallgatózik, amelyre a GCP saját költségvetési riasztó rendszere publikál, ha az

előre beállított kiadási küszöb teljesül. A függvény az Alert-Managerrel közös kódbázisban van megvalósítva, és szintén cooldown mechanizmust alkalmaz. Az eseményt a Firestore `budget_alerts` kollekcióba is naplózza, majd HTML e-mailben értesíti a felhasználót a felhasznált összegről és a küszöbértékről.

4.3.8. Firestore Collections

Az adatbáziskezelő rendszereknek két nagy fajtáját különböztetünk meg, a relációs adatbázisokat, és a nem relációs avagy NoSQL (Not only SQL) adatbázisokat. A fő különbség , hogy a reláciiós adatbázisokban az adatok táblákba rendezettek, és köztük jól meghatározott kapcsolatok vannak. Viszont a NoSql adatbázisokban az adatok úgynevezett dokumentumokban vannak eltárolva, melyek szerkezete sokkal rugalmasabb és nem igényel előre meghatározott sémát. Mivel a projekt főként json formátumú adatokkal dolgozik, így a NoSQL adatbázisok sokkal jobban megfelelnek a céljainknak, és a Firestore egy igen népszerű és megbízható választás ezen a téren.[9]

A rendszer összesen három Firestore kollekciót használ:

Az `alerts` kollekció tárolja a detektált anomáliák bejegyzéseit. Mezői: `camera_id` (melyik kamera észlelte), `detections[]` (a hibák tömbje: név + konfidencia + bounding box), `timestamp` (mikor történt a detekció), `seq` (a képkocka szekvenciaszáma, amelyet a `frame-extractor` biztosít) és `created_at` (mikor került be a bejegyzés). A dashboardon való hatékony keresést egy kompozit index segíti: `camera_id ASC` + `timestamp DESC`, azaz kamera szerint növekvő, időbélyeg szerint csökkenő sorrendben.

Az `alert_cooldowns` kollekció az e-mail értesítések visszatartási idejét kezeli kameránként, megakadályozva a riasztás-özönt rövid időn belül ismétlődő anomáliák esetén.

A `budget_alerts` kollekció a GCP költségvetési riasztásokat naplózza, beleértve a felhasznált összeget, a beállított küszöböt és az esemény időbélyegét.

4.3.9. Konténer képek

A Vertex AI végponton futó detekciós logika egy egyedi Docker konténer képbe (image) van csomagolva, melynek neve `judge`. Ez az image egy Python scriptet tartalmaz, amely induláskor betölti a

betanított YOLOv8 modellt, majd várakozik a bejövő Pub/Sub üzenetekre. Egy üzenet érkezésekor kicsomagolja a base64-kódolt JPEG képkockát, elvégzi rajta az objektumdetekciót, majd az eredményt — a detektált hibaosztályokat és azok konfidenciaértékeit — visszapublikálja a `detections-out` Pub/Sub csatornára.[10] Az image tárolása a Google Artifact Registry-ben történik, verziózva a commit SHA alapján. Minden módosítás esetén a `docker-judge.yml` GitHub Action automatikusan újrabuildi és feltölti a friss image-t, ahonnan a Vertex AI végpont azt lehúzza és futtatja.

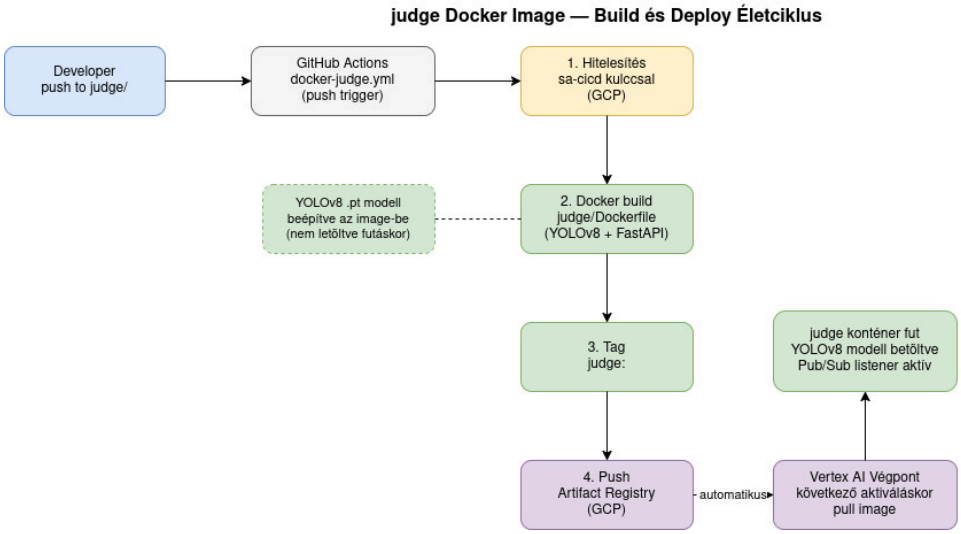

4.4. ábra. A `judge` konténer image életciklusa

4.4. Dashboard

A rendszer felhasználói felülete egy egyoldalas webalkalmazás (Single Page Application), melyet a Firebase Hosting platform szolgál ki, így külön szerver üzemeltetése nélkül érhető el a böngészőből.[11] Az alkalmazás két fő funkciót lát el párhuzamosan.

Egyrészt valós időben jeleníti meg a három kamera videofolyamát WebRTC technológia segítségével, a MediaMTX szerveren és a Cloudflare alagúton keresztül érkező RTSP streamekre támaszkodva. Másrészt a Firebase Firestore adatbázishoz való közvetlen, valós idejű kapcsolaton keresztül (`onSnapshot` listener) azonnal megjelenik minden újonnan detektált anomália, azok neve és konfidenciaértéke, valamint az észlelés időbélyege és a forrás kamera azonosítója.

A dashboard vizuálisan is visszajelzést ad a rendszer állapotáról: amennyiben magas prioritású

anomália érkezik, a felület piros kerettel jelenik meg (CSS `alerting` osztály aktiválásával). Hasonlóan, a költségvetési riasztás esetén sárga kerettel jelez (`budget-alert` osztály), így a felhasználó azonnal értesül a túllépésről anélkül, hogy az e-mailjét kellene ellenőriznie.

[ÁBRA: Dashboard normál nézet screenshot]

4.5. ábra. A dashboard normál működési állapotban

[ÁBRA: Dashboard riasztási állapot screenshot (piros keret)]

4.6. ábra. A dashboard anomália detektálás esetén

4.5. Github Action Workflows

A projekt folyamatos integrációját és automatizált kitelepítését (CI/CD) két GitHub Action workflow biztosítja, melyek a megfelelő kódváltozásra automatikusan lefutnak, csökkentve a manuális beavatkozás szükségességét és az emberi hibák esélyét.[12]

4.5.1. Terraform lépések automatizálása

Ez a workflow a cloud infrastruktúra változtatásait kezeli automatikusan. Pull request esetén csak ellenőrző lépések futnak le, hogy a változtatások biztonságosak és helyesek legyenek merge előtt.

Merge eseményre — a `main` ágra — a workflow elvégzi a tényleges infrastruktúra módosítást a GCP-n.

Konfigurációs ellenőrzés-Chekov

A Checkov egy nyílt forráskódú statikus elemző eszköz, amely Terraform konfigurációkat vizsgál ismert biztonsági problémák és rossz praktikák szempontjából.[13] Futtatása pull request esetén kötelező lépés: amennyiben magas súlyosságú problémát talál — például nyilvánosan elérhető storage bucket vagy nem megfelelő IAM konfiguráció —, a workflow megakadályozza a merge-t. Ez biztosítja, hogy a fejlesztés során se kerülhessen sérülékeny infrastruktúra a produkcióba.

Formázás és erőforráshasználat ellenőrzés-Lint

A linting lépés két dolgot ellenőriz. A `terraform fmt -check` parancs megvizsgálja, hogy a `.tf` fájlok formázása megfelel-e a Terraform hivatalos stílusirányelveknek. A `terraform validate` parancs pedig szintaktikailag és szemantikailag ellenőrzi a konfigurációt, kiszűrve a nem létező erőforrásokra való hivatkozásokat vagy érvénytelen argumentumokat. Ezzel a lépéssel a triviális hibák már a review fázisban kiszűrhetők.

4.5.2. Docker konténer felépítésének automatizálása

Ez a workflow a `judge` Docker image buildjeléért és az Artifact Registry-be való automatikus feltöltéséért felelős. Minden olyan push eseményre lefut, amely a `judge/` könyvtárat érinti — így csak releváns változtatás esetén indul el, nem feleslegesen. A workflow lépései sorban: hitelesítés az `sa-cicd` service account kulcsával, az image buildje, ellátása a commit SHA-val mint egyedi taggel, majd feltöltése a Google Artifact Registry-be. Ezt követően a Vertex AI végpont a következő aktiváláskor automatikusan az új image-t fogja használni.

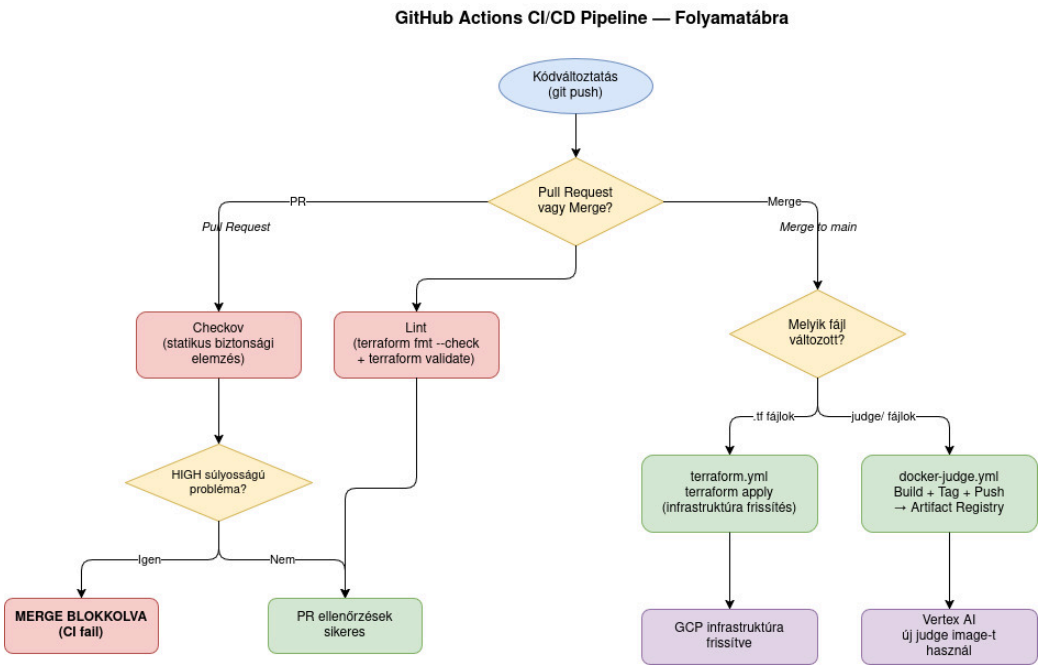

4.7. ábra. A CI/CD pipeline lépései

Összefoglalás

A fejezet bemutatta a rendszer teljes hardver- és szoftverkörnyezetét. Az edge oldalon egy Raspberry Pi 4B gondoskodik a kameraképek rögzítéséről és valós idejű továbbításáról, a felhő oldalon pedig a Google Cloud Platform szolgáltatásai — Pub/Sub, Cloud Functions, Vertex AI, Firestore és Firebase Hosting — alkotják azt a pipeline-t, amely a nyers képkockáktól az anomáliadetekción át a felhasználói értesítésig minden lépést lefed. Az infrastruktúra Terraformmal van definiálva és verziókezelve, a CI/CD pipeline pedig biztosítja, hogy minden kódváltozás automatikusan, emberi beavatkozás nélkül jusson el az éles környezetbe.

5. fejezet

Adatgyűjtés és előfeldolgozás

5.1. Cím 1

6. fejezet

Modell betanítása és validálása

6.1. Cím 1

Eredmények leírása

7. fejezet

Tesztelés és kiértékelés

7.1. Összefoglalás

8. fejezet

Rendszerintegráció és alkalmazás

9. fejezet

Összefoglalás és jövőbeli irányok

10. fejezet

Mellékletek

Irodalomjegyzék

[1] Raspberry Pi Ltd., „Raspberry Pi 4 Model B.” https://www.raspberrypi.com/products/raspberry-pi-4-model-b/, 2024. Hozzáférés: 2026.

[2] bluenviron, „MediaMTX: Ready-to-use SRT / WebRTC / RTSP / RTMP / LL-HLS media server.” https://github.com/bluenviron/mediamtx, 2024. Hozzáférés: 2026.

[3] OpenCV Team, „OpenCV: Open Source Computer Vision Library.” https://opencv.org/, 2024. Hozzáférés: 2026.

[4] Cloudflare Inc., „Cloudflare Tunnel Documentation.” https://developers.cloudflare.com/cloudflare-one/connections/connect-networks/, 2024. Hozzáférés: 2026.

[5] HashiCorp Inc., „Terraform: Infrastructure as Code.” https://developer.hashicorp.com/terraform/intro, 2024. Hozzáférés: 2026.

[6] Google LLC, „Google Cloud Platform Documentation.” https://cloud.google.com/docs, 2024. Hozzáférés: 2026.

[7] Ultralytics, „YOLOv8: A new state-of-the-art computer vision model.” https://github.com/ultralytics/ultralytics, 2023. Hozzáférés: 2026.

[8] Google LLC, „Google Cloud Pub/Sub Documentation.” https://cloud.google.com/pubsub/docs, 2024. Hozzáférés: 2026.

[9] Google LLC, „Cloud Firestore Documentation.” https://firebase.google.com/docs/firestore, 2024. Hozzáférés: 2026.

[10] Google LLC, „Vertex AI: Use a custom container for prediction.” https://cloud.google.com/vertex-ai/docs/predictions/use-custom-container, 2024. Hozzáférés: 2026.

[11] Google LLC, „Firebase Hosting Documentation.” https://firebase.google.com/docs/hosting, 2024. Hozzáférés: 2026.

[12] GitHub Inc., „GitHub Actions Documentation.” https://docs.github.com/en/actions, 2024. Hozzáférés: 2026.

[13] Bridgecrew Inc., „Checkov: Static code analysis tool for infrastructure as code.” https://www.checkov.io/, 2024. Hozzáférés: 2026.

A. függelék

Függelék

A.1. Alfejezet

A.1.1. Cím

Alcím